UNIVERSIDAD AUTÓNOMA DE SANTO DOMINGO · MAESTRÍA EN CIENCIAS DE DATOS E INTELIGENCIA ARTIFICIAL

Autoencoder y VAE con Fashion-MNIST

Mandato · Ejercicio 06 · Informe de entrega

Asignatura	INF-8239 Ciencia de Datos II
Unidad	03 · Algoritmos y Características Generativas
Código	U03.E06
Estudiante	Alexis De La Cruz · Matrícula 100805370
Fecha	19 de octubre de 2026
Entorno	Windows 11 · Intel i9-13980HX · RAM 16 GB · NVIDIA RTX 4070 Laptop, 8 GB · Python 3.12.12 · TensorFlow 2.21.0

1. Repositorio y propósito

Enlace: https://github.com/delaxis1/INF8239_U03_Generativos

Comparar reconstrucción y generación sobre el proyecto base LAB10 de Edwin Ramón José Nolasco. Se entregan notebook ejecutado, modelos, pruebas, aplicación local y Model Card. El AE comprime una entrada; el VAE aprende una distribución latente regularizada.

2. Datos y protocolo

Fashion-MNIST, fuente oficial Zalando Research, licencia MIT. 60,000 imágenes de desarrollo se separan en 54,000 ajuste y 6,000 validación; 10,000 de prueba oficial. Normalización float32/255; archivos verificados con SHA-256. Etiquetas reservadas para análisis por clase.

Semilla 42, lote 256. AE 16: 6 épocas; VAE 2: 8 épocas con β=1 y β=0.1. Se preservan las arquitecturas de la base; capacidad y tamaño latente distintos impiden aislar solo el efecto de KL. Los 16 casos de prueba y las 256 muestras nuevas se fijan con semillas, sin escoger los mejores.

3. Resultados y elección previa a prueba

Modelo	MSE prueba	SSIM	KL prueba	Época elegida
AE · latente 16	0.02040	0.5365	—	6
VAE · β=1	0.03361	0.4176	6.278	8
VAE · β=0.1	0.03134	0.4388	19.290	8

Selección: **VAE · β=1**, por menor reconstrucción sumada + KL de validación con peso común 1. La decisión se registró antes de prueba. AE usa menor BCE de validación. VAE reconstruye desde μ para comparar pares de forma determinista.

4. Panel fijo: reconstrucción y generación



Figura 1. Dieciséis casos de prueba seleccionados con semilla 2026. Cada bloque presenta originales, AE, VAE desdeμ y muestras nuevas del prior N(0,I), semilla 31415. La última fila es generación libre: no corresponde a la original de la columna.

MSE y SSIM describen similitud con una referencia emparejada. No demuestran calidad de las muestras nuevas. El panel permite observar pérdida de detalles, siluetas ambiguas y variación; su selección se conserva en visual_evidence.npz.

Clases con mayor error del VAE elegido	MSE	Casos
Bolso	0.06440	1000
Sandalia	0.03893	1000
Botín	0.03495	1000

El bolso del caso 797 pierde sus asas y se aproxima a una prenda superior; los estampados finos del caso 7211 se diluyen. Son fallos visibles del panel fijado, no ejemplos añadidos después de revisar resultados.

5. Curvas, espacio latente y vecinos

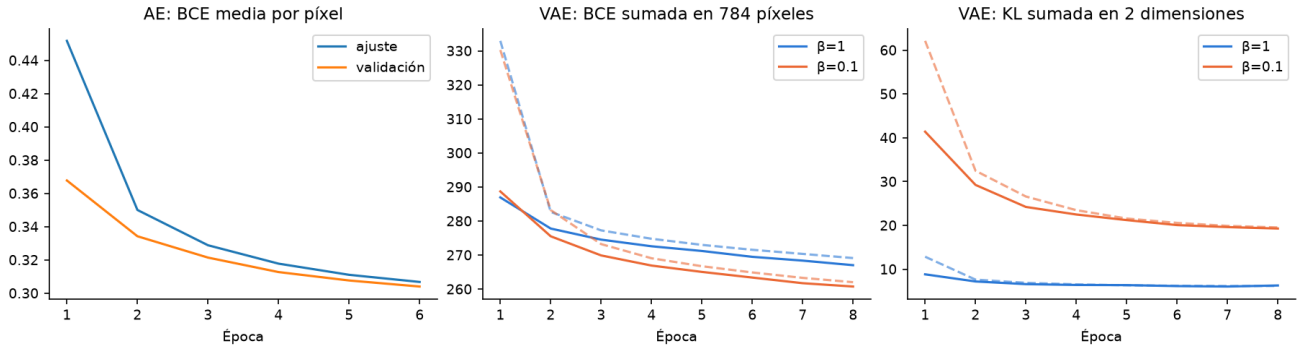


Figura 2. Reconstrucción y KL separadas. En VAE, línea continua=validación y discontinua=ajuste. AE promedia BCE por píxel; VAE la suma en 784 píxeles y KL en 2 dimensiones, con promedio por imagen. La escala de sus pérdidas no se compara directamente.

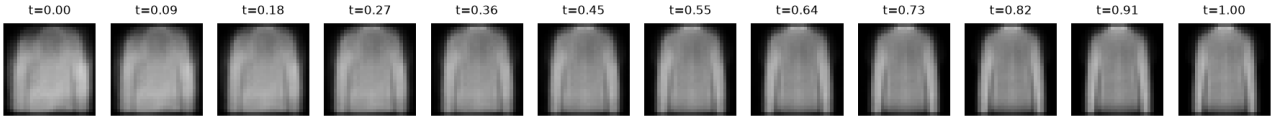


Figura 3. Interpolación entre las medias latentes de los primeros dos casos del panel. La continuidad no implica ejes con significado semántico garantizado.

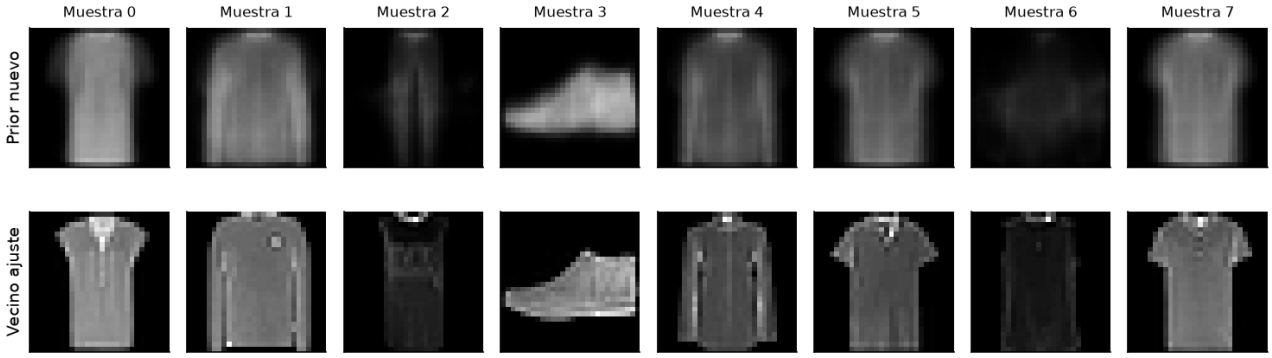


Figura 4. Primeras ocho muestras del prior y vecino exacto en píxeles entre 54,000 imágenes de ajuste. No se ordenaron por parecido.

Diagnóstico sobre 256 muestras	Generadas	Referencia real
Diversidad media entre pares (MSE)	0.06726	0.17195
Mediana MSE al vecino de entrenamiento	0.00896	0.01450

Referencia real: 256 casos de validación, semilla 2718. La proximidad puede reflejar una forma promedio; no demuestra copia. Estas medidas no son FID ni una garantía de privacidad, diversidad de clases u originalidad.

6. Costo y conclusión

Modelo	Ajuste (s)	Inferencia (ms/img)	Tamaño (KiB)
AE · latente 16	3.0	0.008	122.5
VAE · β=1	7.6	0.017	833.0
VAE · β=0.1	7.4	0.016	833.0

Latencia mediana tras calentamiento, lote 256. Tamaño VAE incluye encoder+decoder. Pico working set del proceso: 1180.0 MiB. Costos dependientes del equipo y su carga.

Esta práctica me ayudó a separar dos resultados que al principio podían parecer lo mismo: reconstruir una prenda y generar una imagen nueva. El autoencoder recibe una imagen concreta e intenta conservarla después de comprimirla. El VAE añade una distribución latente y una penalización KL para poder explorar ese espacio mediante muestreo. Por eso decidí mirar las reconstrucciones y las muestras del prior por separado, sin presentar una muestra nueva como si correspondiera a la imagen de prueba que aparece encima.

El autoencoder obtuvo MSE 0.02040, menor que el 0.03361 del VAE seleccionado. Sus SSIM fueron 0.5365 y 0.4176, respectivamente. Estas cifras describen reconstrucción de las mismas diez mil imágenes de prueba. No permiten atribuir toda la diferencia a KL: la base también usa arquitecturas y tamaños latentes distintos, dieciséis dimensiones en AE y dos en VAE. Mantener esa distinción me parece necesario para no sacar una conclusión más amplia que el experimento.

Comparé dos pesos de regularización con la misma semilla, partición y presupuesto. La validación seleccionó VAE · β=1, utilizando reconstrucción sumada más KL con peso común uno. Registré esa decisión antes de evaluar prueba. Elegir por las pérdidas totales originales habría sido confuso, porque cada beta cambia la escala del término KL. Las curvas separadas permiten ver qué parte del objetivo cambia durante el entrenamiento y evitan confundir una pérdida baja con una buena generación.

Para la parte generativa utilicé doscientas cincuenta y seis muestras con semilla fija. Su diversidad media en píxeles fue 0.06726, frente a 0.17195 en la referencia real. Esa comparación muestra variación, pero no mide cobertura de clases ni calidad humana. También busqué vecinos entre las cincuenta y cuatro mil imágenes de ajuste. La mediana de distancia fue 0.00896. Encontrar parecido no demuestra copia; encontrar diferencias tampoco garantiza privacidad. Los paneles y la interpolación sirven para examinar esos límites de forma visible.

Mi decisión es conservar el AE como referencia de reconstrucción y usar el VAE elegido en una demostración local del espacio latente. El experimento completo tomó 0.4 minutos y se puede repetir con los archivos, semillas y dependencias registrados. Antes de darle un uso más exigente, repetiría el ajuste con otras semillas, ampliaría la evaluación perceptual y revisaría los ejemplos con personas. Lo entregado es una comparación educativa comprobable, con una sola semilla de entrenamiento y sin garantías de originalidad, equidad o privacidad.

7. Referencias y nota del autor

Kingma, D. P., & Welling, M. (2013). *Auto-Encoding Variational Bayes*. doi:10.48550/arXiv.1312.6114. Zalando Research. (s. f.). *Fashion-MNIST* [Dataset, MIT]. github.com/zalandoresearch/fashion-mnist. Nolasco, E. R. J. (s. f.). *LAB10 y aclaraciones U03* [Material de curso]. UASD.

Codex (OpenAI) apoyó código, verificación y redacción. Procedencia, prompts y correcciones se documentan en AI_USE_DECLARATION.md. Conclusión como borrador para revisión personal del estudiante.